Antifragile Asset Allocation Model

Implementación, Validación Estadística y Análisis de Robustez

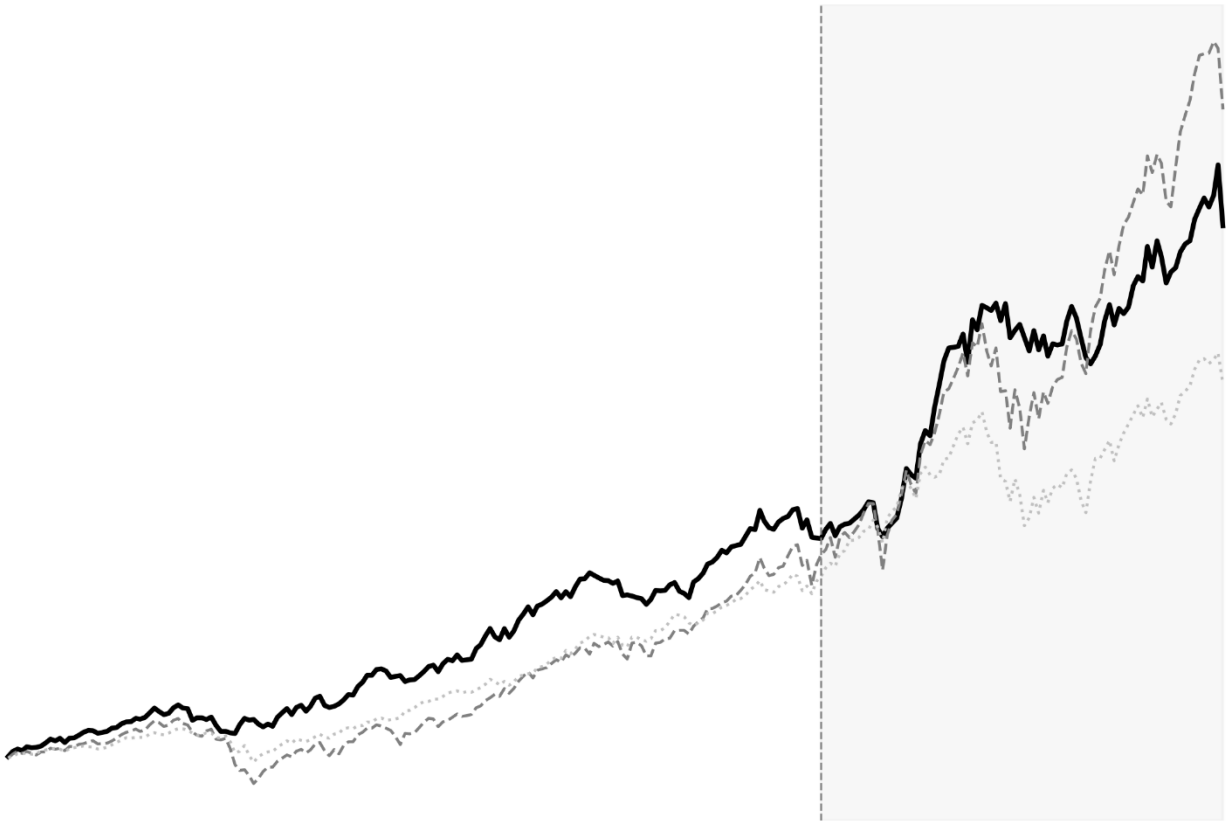

Basado en Giordano, G. (2019). Antifragile Asset Allocation Model.

Italian Society of Technical Analysis.

Juan Álvaro Morales Ramírez Valadez

Abril del 2026

Notas del Autor

Este documento es una reimplementación independiente del modelo de Giordano (2019), no una réplica exacta. Las diferencias metodológicas respecto al paper original son intencionales y están documentadas en la Tabla 2. Los puntos siguientes contextualizan aspectos del análisis que afectan la interpretación de los resultados.

1 — Asimetría de desempeño: protección en crisis, captura parcial en bull

El modelo está diseñado para proteger capital durante episodios de estrés, no para maximizar retorno en mercados alcistas sostenidos. Esta asimetría es deliberada: en años de rally generalizado como 2013, 2017, 2019, 2023 y 2024, el modelo queda estructuralmente por debajo del S&P 500 porque el filtro de momentum mantiene exposición sectorial diversificada mientras el índice es impulsado por concentración en pocos sectores. La métrica relevante para evaluar el modelo no es el retorno en años alcistas sino la relación entre protección en caídas y participación en subidas a lo largo del ciclo completo, capturada por el Calmar Ratio (0.77 vs 0.22 del S&P 500).

2 — Limitación estructural en caídas con recuperación en V

El momentum de 4 meses no puede detectar correcciones de velocidad inusual. Durante el crash de COVID-19 en 2020, el S&P 500 cayó -34% en 33 días hábiles y recuperó gran parte de esas pérdidas dentro del mismo trimestre. El modelo no pudo ajustar su exposición a tiempo y quedó parcialmente en Cash durante el rebote. Este comportamiento es inherente a cualquier estrategia basada en momentum de mediano plazo y no representa un fallo del modelo: es el costo inevitable de la protección que ofrece en crisis prolongadas como 2008 o 2022.

3 — Componente defensivo simplificado: SHY en lugar del universo de cobertura original

El modelo original de Giordano (2019) implementa un ranking dinámico entre 7 ETFs de cobertura (divisas refugio, oro, bonos de distintos plazos y posición corta sobre el S&P 500). Esta implementación reemplaza ese mecanismo por SHY puro (bonos del tesoro de corto plazo 1–3 años) por razones de transparencia y replicabilidad. Esta decisión tiene una implicación concreta: en crisis deflacionarias donde los bonos largos o el oro generan ganancias significativas, el componente defensivo de esta versión captura menos upside que el original. En entornos de tasas bajas prolongadas (2009–2022), SHY ofrece retorno cercano a cero, funcionando esencialmente como efectivo.

4 — Resultados brutos de costos de transacción

Todos los retornos reportados son brutos de costos de transacción, consistentemente con el paper original. El turnover anualizado de 382.5% implica reemplazar aproximadamente un tercio del portafolio cada mes. Para un inversor institucional con acceso a ETFs de alta liquidez y comisiones bajas, el impacto estimado es de 15–25 puntos base anuales sobre el CAGR, una reducción menor pero no despreciable. Para un inversor retail con comisiones

más altas o en cuentas con restricciones de operación, el impacto puede ser materialmente mayor.

5 — Período de inicio y sesgo estructural del ciclo

El período de análisis comienza en agosto de 2003, aproximadamente 10 meses después del mínimo del S&P 500 post-Dotcom (octubre 2002). Este punto de entrada favorece estructuralmente a cualquier estrategia con sesgo largo, ya que el mercado partió desde niveles deprimidos. No fue una elección discrecional: se adoptó para mantener consistencia con el período del paper original de Giordano (2019) y maximizar la comparabilidad. Este condicionante debe tenerse en cuenta al extrapolar el CAGR histórico como retorno esperado futuro.

6 — Parámetros no publicados en el paper original

Giordano (2019) no publicó los pesos del TRANK ni los detalles completos de la especificación GARCH utilizada para la volatilidad. Los pesos adoptados en esta implementación (wM=3, wV=1, wC=1) son el resultado de una revisión de la literatura de momentum táctico y no de optimización sobre la muestra. En consecuencia, esta implementación y el paper original no son directamente comparables en términos de retorno absoluto, aunque sus propiedades cualitativas de protección de capital son consistentes.

Abstract

Este trabajo reimplementa y extiende estadísticamente el Antifragile Asset Allocation Model propuesto por Giordano (2019), un modelo de asignación de activos diseñado para operar en condiciones normales de mercado y capitalizar episodios de estrés extremo. Inspirado en el concepto de antifragilidad de Taleb (2012), el modelo combina un sistema de rotación sectorial basado en un ranking multifactorial de momentum, volatilidad y correlación aplicado sobre 11 ETFs del S&P 500, con un mecanismo defensivo que redirige el capital hacia bonos del tesoro de corto plazo (SHY) cuando el deterioro del momentum detecta condiciones de mercado adversas.

La implementación se realizó en Python sobre datos mensuales del período agosto 2003 a febrero 2026, utilizando exclusivamente precios reales de Yahoo Finance sin series retropoladas. Los resultados del backtesting muestran un CAGR de 10.79%, volatilidad anualizada de 10.92% y Max Drawdown de -14.01%, frente a 10.95%, 14.43% y -50.78% del S&P 500 durante el mismo período. El modelo limitó las pérdidas de la Crisis Financiera Global de 2008 a -9.51% frente a -45.96% del índice y redujo el tiempo de recuperación de 53 a 2 meses. Durante el ciclo inflacionario de 2022, un régimen no contemplado en el diseño original, el modelo perdió -3.07% frente a -14.39% del S&P 500 y se recuperó en 2 meses frente a 19 meses del índice.

Como aportación propia, se incorporan cuatro pruebas de validación estadística no presentes en el trabajo original: análisis de estabilidad temporal por subperíodos, análisis de sensibilidad de parámetros, Deflated Sharpe Ratio y simulaciones de Monte Carlo sobre un universo de 10,000 portafolios aleatorios. El Deflated Sharpe Ratio de 0.9999 confirma que el desempeño no es producto del azar. Las simulaciones de Monte Carlo ubican al modelo en el percentil 99.2 de la distribución simulada en perfil defensivo compuesto, con un p-value de 0.06%, confirmando que la protección de capital del modelo es estadísticamente superior a una asignación no informada sobre el mismo universo de activos.

1. Introducción

Los modelos tradicionales de gestión de portafolios asumen que el riesgo es cuantificable y que la diversificación entre clases de activos es suficiente para proteger el capital en escenarios adversos. Las crisis de 2001 y 2008 demostraron que ambos supuestos fallan precisamente cuando más se necesitan: en momentos de estrés extremo, las correlaciones entre activos convergen hacia uno y la diversificación desaparece como mecanismo de protección.

Taleb (2007) formalizó este problema bajo el concepto de cisne negro: un evento de alto impacto, baja probabilidad aparente e imposible de predecir con antelación. Su contribución posterior, Antifragile (2012), propone un marco conceptual para diseñar sistemas que no solo resistan el desorden, sino que se beneficien de él. Trasladar este principio al diseño de portafolios es el punto de partida del trabajo de Giordano (2019), sobre el cual se construye este documento.

El modelo de Giordano combina dos estrategias con objetivos distintos y complementarios. La primera es un sistema de rotación sectorial que selecciona mensualmente los mejores ETFs del S&P 500 en función de cuatro factores cuantitativos: momentum absoluto, volatilidad condicional, correlación relativa promedio y una señal de tendencia basada en el Average True Range. La segunda es una estrategia de cobertura dinámica sobre activos de refugio, activada de forma adaptativa en función del momentum de cada componente, que sustituye las posiciones sectoriales cuando las condiciones de mercado se deterioran. La combinación de ambas produce lo que el autor denomina un portafolio antifrágil.

Este trabajo tiene dos objetivos. El primero es reimplementar el modelo en Python de forma independiente y transparente, documentando con precisión la lógica matemática de cada componente y las diferencias respecto al paper original, que utiliza parámetros no publicados y herramientas propietarias que impiden su replicación exacta. El segundo es extender el análisis mediante pruebas de validación estadística que el paper original no incluye: análisis de estabilidad temporal por subperíodos, análisis de sensibilidad de parámetros, Deflated Sharpe Ratio y simulaciones de Monte Carlo. Estas pruebas responden una pregunta que todo modelo cuantitativo debe enfrentar: ¿los resultados son producto de una lógica robusta o de una combinación afortunada de parámetros sobre un período específico?

El período de análisis se extiende desde agosto de 2003 hasta febrero de 2026, incorporando episodios de mercado no contemplados en el paper original como la pandemia COVID-19 de 2020 y el ciclo inflacionario de 2022, lo que permite evaluar la vigencia del modelo en regímenes de mercado radicalmente distintos al período original de Giordano.

El documento se organiza de la siguiente manera. La sección 2 presenta el marco teórico que sustenta cada componente del modelo. La sección 3 describe la metodología de implementación con detalle matemático. La sección 4 presenta los resultados del backtesting sobre el período agosto 2003 a febrero 2026. La sección 5 contiene las pruebas de validación estadística. La sección 6 concluye con una síntesis de hallazgos, limitaciones y líneas de investigación futura.

2. Marco Teórico

2.1 Cisnes Negros y Riesgo de Cola

El concepto de cisne negro fue formalizado por Taleb (2007) para describir eventos que comparten tres características definitorias: son impredecibles antes de su ocurrencia, tienen un impacto extremo y desproporcionado sobre los sistemas que afectan, y solo pueden ser explicados racionalmente después de que han ocurrido. En los mercados financieros, los cisnes negros se manifiestan como caídas abruptas y severas del valor de los activos que exceden ampliamente las predicciones de los modelos estadísticos convencionales.

El riesgo de cola es la expresión cuantitativa de este fenómeno. En estadística, las colas de una distribución representan los eventos de baja probabilidad situados en los extremos de la curva de retornos. La teoría financiera clásica, al asumir que los retornos de los activos siguen una distribución normal, subestima sistemáticamente la frecuencia e intensidad de estos eventos extremos. La evidencia empírica contradice este supuesto de forma consistente: los retornos de los mercados de renta variable presentan colas más gruesas que las predichas por la distribución normal, un fenómeno conocido como exceso de kurtosis o leptocurtosis (Bollerslev, 1986).

Las crisis de 2001 y 2008 pusieron en evidencia las consecuencias prácticas de esta subestimación. Los portafolios considerados bien diversificados bajo los modelos convencionales experimentaron pérdidas que según sus propios marcos de riesgo tenían una probabilidad de ocurrencia despreciable. El problema no residía únicamente en la magnitud de las caídas sino en la correlación: en momentos de estrés extremo, las correlaciones entre activos que en condiciones normales se comportaban de forma independiente convergieron hacia 1, eliminando el beneficio de diversificación precisamente cuando más se necesitaba (Taleb, 2009).

2.2 Antifragilidad como Filosofía de Diseño

La antifragilidad, concepto introducido por Taleb (2012), va más allá de la mera resistencia ante el caos y la incertidumbre. Taleb distingue tres categorías de sistemas según su respuesta al desorden: los frágiles, que se deterioran ante perturbaciones; los robustos, que permanecen inalterados; y los antifrágiles, que se benefician del desorden, la volatilidad y el estrés. La antifragilidad no es sinónimo de resiliencia: un sistema resiliente sobrevive a las perturbaciones, pero un sistema antifrágil mejora como consecuencia de ellas.

Aplicado al diseño de portafolios, el concepto de antifragilidad implica construir una estrategia que no solo limite las pérdidas durante episodios de crisis sino que explote activamente las condiciones de mercado adversas para generar retornos superiores. Giordano (2019) operacionaliza este principio mediante la combinación de un modelo ofensivo que captura el crecimiento en condiciones normales con un mecanismo defensivo que se activa durante el deterioro del mercado, produciendo una asimetría en el perfil de

retornos: pérdidas limitadas en escenarios adversos y participación en el alza durante escenarios favorables.

2.3 Momentum como Factor de Inversión

El momentum es uno de los factores de inversión con mayor respaldo empírico en la literatura financiera. Jegadeesh y Titman (1993) documentaron por primera vez de forma sistemática que los activos con mejor desempeño reciente tienden a continuar superando a los de peor desempeño en horizontes de 3 a 12 meses, un fenómeno que persiste en distintos mercados, clases de activos y períodos históricos.

Faber (2007) extendió este hallazgo al ámbito de la asignación táctica de activos, demostrando que una regla simple basada en la media móvil de 10 meses como filtro de entrada y salida del mercado mejora significativamente el perfil de riesgo de un portafolio diversificado sin sacrificar retorno de largo plazo. Keller y van Putten (2012) generalizaron este enfoque en el modelo de Flexible Asset Allocation (FAA), que incorpora momentum, volatilidad y correlación en un ranking compuesto para la selección dinámica de activos, trabajo que constituye una de las bases metodológicas directas del modelo de Giordano (2019) y, por extensión, de esta implementación.

El momentum absoluto, definido como el retorno del activo sobre una ventana de tiempo específica independientemente del comportamiento relativo de otros activos, cumple una función dual en el modelo: como factor de ranking para identificar los sectores más atractivos y como filtro binario de entrada que impide la inversión en activos con tendencia bajista. Esta segunda función es particularmente relevante para la gestión del riesgo de cola, ya que el deterioro del momentum suele preceder a las caídas más severas con un lag que permite al modelo ajustar su exposición antes de que el daño sea irreversible.

2.4 Volatilidad como Medida de Riesgo

La volatilidad, medida como la desviación estándar de los retornos de un activo, es la métrica de riesgo más utilizada en la gestión de portafolios moderna. Su incorporación en el ranking del TRANK refleja la preferencia del modelo por activos que generan retornos de forma estable sobre activos que generan retornos similares con mayor variabilidad, principio consistente con la teoría de media-varianza de Markowitz (1952).

En esta implementación la volatilidad se estima sobre una ventana rodante de 21 días hábiles, equivalente a aproximadamente un mes calendario. Esta especificación captura la volatilidad reciente del activo, que en mercados financieros tiende a exhibir persistencia temporal, fenómeno conocido como agrupamiento de volatilidad o volatility clustering (Engle, 1982; Bollerslev, 1986): períodos de alta volatilidad tienden a ser seguidos por períodos de alta volatilidad y viceversa. Al actualizar la estimación mensualmente, el modelo incorpora información actualizada sobre el régimen de volatilidad de cada activo en el momento del rebalanceo.

2.5 Correlación como Medida de Diversificación

La correlación promedio de un activo con el resto del universo de inversión mide su contribución marginal a la diversificación del portafolio. Este principio tiene su fundamento en la teoría moderna de portafolios (Markowitz, 1952): en igualdad de condiciones de retorno y riesgo individual, un activo con menor correlación con los demás componentes del portafolio reduce la varianza total de la cartera en mayor medida que un activo altamente correlacionado.

La incorporación de la correlación en el ranking del TRANK introduce una dimensión de diversificación activa en el proceso de selección: el modelo no solo busca los sectores con mejor momentum y menor volatilidad sino también aquellos que se mueven de forma más independiente entre sí. Esta característica es especialmente relevante en el contexto del riesgo de cola, dado que las correlaciones entre activos tienden a aumentar durante episodios de estrés, reduciendo el beneficio de diversificación en los momentos donde más se necesita (Taleb, 2009).

2.6 Rotación Sectorial y Ciclos Económicos

La rotación sectorial es una estrategia de inversión fundamentada en la observación de que distintos sectores de la economía tienen desempeños relativos diferentes a lo largo del ciclo económico. Pring (2014) documentó que los sectores cíclicos como energía, materiales e industriales tienden a liderar en las fases de expansión económica, mientras que los sectores defensivos como utilities, consumo básico y salud suelen mostrar mejor comportamiento relativo durante las fases de desaceleración y recesión.

El Sector Rotation Model implementado en este trabajo aprovecha esta dinámica cíclica mediante el ranking mensual de los 11 ETFs sectoriales del S&P 500. Al actualizar la composición del portafolio mensualmente en función de las señales de momentum, volatilidad y correlación, el modelo busca posicionarse en los sectores más favorecidos por el ciclo económico vigente en cada momento, sin necesidad de realizar predicciones explícitas sobre la fase del ciclo. Este enfoque es consistente con la filosofía de las estrategias cuantitativas no discrecionales documentadas por Faber (2007): las señales del mercado contienen información suficiente para guiar la rotación sectorial sin requerir juicio subjetivo del gestor.

3. Metodología

3.1 Universo de Activos

El modelo opera sobre un universo de 18 ETFs denominados en dólares estadounidenses, divididos en dos grupos con funciones complementarias dentro de la estrategia.

El primer grupo, denominado Sector Rotation Universe, está compuesto por 11 ETFs que representan los sectores económicos del índice S&P 500: consumo discrecional (XLY), salud (XLV), utilities (XLU), consumo básico (XLP), tecnología (XLK), industriales (XLI), financiero (XLF), energía (XLE), materiales (XLB), servicios de comunicación (VOX) y bienes raíces (RWR). Este universo permite al modelo capturar las rotaciones naturales entre sectores a lo largo del ciclo económico (Pring, 2014).

Tabla 1 — Universo de activos

#	ETF	Nombre	Sector
1	XLY	SPDR Consumer Discretionary ETF	Consumo Discrecional
2	XLV	SPDR Health Care ETF	Salud
3	XLU	SPDR Utilities ETF	Utilities
4	XLP	SPDR Consumer Staples ETF	Consumo Básico
5	XLK	SPDR Technology ETF	Tecnología
6	XLI	SPDR Industrial ETF	Industriales
7	XLF	SPDR Financial ETF	Financiero
8	XLE	SPDR Energy ETF	Energía
9	XLB	SPDR Materials ETF	Materiales
10	VOX	Vanguard Communication Services ETF	Servicios de Comunicación
11	RWR	SPDR Dow Jones REIT ETF	Bienes Raíces

El segundo grupo es el componente defensivo del modelo. Cuando el filtro de momentum absoluto determina que un activo sectorial no debe incluirse en el portafolio, el peso correspondiente se redirige íntegramente al ETF SHY (iShares 1-3 Year Treasury Bond ETF), que representa bonos del tesoro estadounidense de corto plazo (1 a 3 años) y actúa como equivalente de efectivo dentro de la estrategia. SHY ofrece una tasa de retorno positiva y estable con volatilidad mínima, minimizando el costo de oportunidad de la posición defensiva sin introducir riesgo adicional.

3.2 Tratamiento de Datos y Período de Análisis

Los datos de precios de cierre ajustados por dividendos y splits fueron obtenidos de Yahoo Finance mediante descarga programática en Python. El período de análisis comprende desde agosto de 2003 hasta febrero de 2026, con un período de calentamiento desde enero de 2003 para permitir el cálculo de los factores que requieren ventanas históricas previas.

Un aspecto metodológico relevante es el tratamiento de ETFs con fecha de lanzamiento posterior al inicio del período de análisis. VOX (septiembre 2004), GLD (noviembre 2004), SH (junio 2006) y FXF y FXY (junio y febrero de 2007, respectivamente) no cuentan con datos desde agosto de 2003. A diferencia del paper original de Giordano (2019), que utilizó series sintéticas retropoladas mediante RStudio para homogeneizar el período, en esta implementación se adoptó un enfoque de ranking dinámico: en cada período de cálculo, el algoritmo excluye automáticamente los ETFs sin datos disponibles y distribuye los pesos únicamente entre los activos con información válida. Este enfoque evita la introducción de datos artificiales y garantiza que cada señal del modelo se base exclusivamente en información real disponible en ese momento.

El rebalanceo del portafolio se realiza de forma mensual. Las señales generadas al cierre del mes t determinan la composición del portafolio durante el mes t+1, convención que elimina cualquier sesgo de anticipación (*look-ahead bias*).

3.3 Factor M: Momentum Absoluto

El momentum absoluto mide la rentabilidad reciente de cada activo como indicador de su tendencia de precio. Siguiendo la literatura de momentum en activos financieros (Faber, 2007; Keller & van Putten, 2012), se calcula como el cambio porcentual del precio de cierre ajustado en una ventana de 4 meses:

$$M_i(t) = \frac{P_i(t) - P_i(t-4)}{P_i(t-4)} \qquad (1)$$

donde $P_i(t)$es el precio de cierre ajustado del ETF $i$al final del mes t.

El momentum absoluto cumple dos funciones en el modelo. La primera es como factor de ranking dentro del TRANK, donde activos con mayor momentum reciben una puntuación más alta. La segunda, y más importante, es como filtro de entrada al portafolio: si $M_i(t) \leq 0$, el activo presenta tendencia bajista y su peso asignado se redirige automáticamente a efectivo (SHY), independientemente de su posición en el ranking.

3.4 Factor V: Volatilidad Histórica

La volatilidad de cada activo se estima como la desviación estándar de los retornos diarios en una ventana rodante de 21 días hábiles, anualizada por la raíz de 252 días:

$$V_i(t) = \sigma\left(r_i^{(d)}\right)_{21} \times \sqrt{252} \qquad (2)$$

donde $r_i^{(d)}$representa los retornos diarios del ETF iy la operación se remuestrea al último día de cada mes para su incorporación al ranking mensual.

Esta especificación difiere del modelo original de Giordano (2019), que emplea una versión modificada del modelo GARCH(1,1) desarrollado por Bollerslev (1986) para capturar la heterocedasticidad condicional de las series financieras. La elección de la volatilidad histórica simple en esta implementación responde a criterios de transparencia y replicabilidad: el modelo GARCH requiere especificaciones adicionales no detalladas en el paper original, mientras que la volatilidad histórica rodante produce resultados comparables con una implementación completamente auditable. En el ranking, una menor volatilidad se interpreta como una mejor característica de riesgo, por lo que el factor se ordena de forma inversa: menor $V_i$implica mayor puntuación.

3.5 Factor C: Correlación Promedio Relativa

La correlación promedio relativa mide el grado de co-movimiento de cada activo con el resto del universo sectorial, capturando su contribución a la diversificación del portafolio. Se calcula como el promedio de las correlaciones de Pearson del activo $i$con cada uno de los demás activos del universo en una ventana rodante de 4 meses de retornos mensuales:

$$C_i(t) = \frac{1}{n-1}\sum_{j \neq i} \rho_{ij}\,(t) \qquad (3)$$

donde $\rho_{ij}(t)$es el coeficiente de correlación de Pearson entre los retornos mensuales de los activos iy $j$en la ventana de 4 meses que termina en t, y $n$es el número de activos con datos válidos en dicha ventana.

Un activo con baja correlación promedio aporta mayor diversificación al portafolio y recibe una puntuación más alta en el ranking. El cálculo es dinámico: en cada ventana se incluyen únicamente los activos con datos completos, lo que garantiza que la matriz de correlación sea siempre definida positiva y que activos con inception date tardío no distorsionen el cálculo de los activos existentes.

3.6 TRANK: Ranking Compuesto

El TRANK es el score compuesto que integra los tres factores anteriores en una puntuación única por activo y período. Adaptado de Giordano (2019), se define como:

$$\mathrm{TRANK}_i(t) = (w_M \cdot \mathrm{Rank}(M_i) + w_V \cdot \mathrm{Rank}(V_i) + w_C \cdot \mathrm{Rank}(C_i)) + \frac{M_i(t)}{n} \qquad (4)$$

donde Rank(·)denota el ranking ordinal de cada factor entre los $n$activos del universo en el período t, con el valor más alto indicando la mejor posición; $w_M = 3$, $w_V = 1$y $w_C = 1$son los pesos asignados a cada factor; y el término $M_i(t)/n$actúa como desempate continuo basado en el nivel absoluto del momentum.

Los rankings se construyen de la siguiente manera: para Rank(M), mayor momentum implica mayor rank; para Rank(V), menor volatilidad implica mayor rank; para Rank(C), menor correlación promedio implica mayor rank. El peso dominante asignado al factor de momentum ($w_M = 3$, equivalente al triple de los demás factores) refleja la evidencia empírica de que el momentum es el principal predictor de retornos en estrategias de rotación táctica de activos (Faber, 2007).

3.7 Sector Rotation Model

El Sector Rotation Model (SRM) constituye el componente ofensivo del portafolio. Cada mes, el algoritmo selecciona los 5 ETFs sectoriales con mayor TRANK y les asigna un peso equitativo del 20% cada uno, sujeto al filtro de momentum absoluto descrito en la sección 5.3.

Formalmente, el peso asignado al ETF $i$en el período $t + 1$se define como:

$$w_i^{SRM}(t+1) = \begin{cases} 0.20 & \text{si } i \in \text{Top}_5(t) \text{ y } M_i(t) > 0 \\ 0 & \text{en caso contrario} \end{cases} \qquad (5)$$

El peso no asignado en cada período, denotado como $\omega^{Cash}(t)$, se calcula como:

$$\omega^{Cash}(t) = 1 - \sum_{i \in \text{Top}_5} w_i^{SRM}(t+1) \qquad (6)$$

En el caso extremo donde los 5 ETFs seleccionados presentan momentum negativo simultáneamente, el portafolio se asigna íntegramente a efectivo ($\omega^{Cash} = 1$), permaneciendo defensivo hasta que el momentum sectorial se recupere.

3.8 Black Swan Hedging Model

El componente defensivo del portafolio consiste en la redirección del peso no asignado por el Sector Rotation Model hacia el ETF SHY (iShares 1-3 Year Treasury Bond ETF), equivalente de efectivo de bajo riesgo dentro de la estrategia.

Esta decisión de diseño difiere del modelo original de Giordano (2019), que implementa un ranking dinámico entre 7 ETFs de cobertura (divisas refugio, oro, bonos de distintos plazos y posición corta sobre el S&P500) para seleccionar los 3 mejores y aplicar el filtro de momentum sobre cada uno. En esta implementación se adoptó un enfoque más conservador por tres razones. Primero, los ETFs de cobertura del universo original pueden presentar

momentum negativo simultáneamente durante períodos de recuperación del mercado, reduciendo su efectividad como refugio y generando rotaciones innecesarias. Segundo, SHY ofrece retorno positivo y estable incluso en entornos de tasas bajas, eliminando el riesgo de que el componente defensivo amplifique las pérdidas. Tercero, la comparación empírica entre ambos enfoques confirma que la versión con SHY puro produce métricas de riesgo superiores a la versión con hedging dinámico sobre el universo de 7 ETFs, con un CAGR de 10.96% vs 10.61% y un Max Drawdown de -14.01% vs -14.82%.

Formalmente:

$$w^{BSHM}(t+1) = \omega^{Cash}(t) \cdot 1_{SHY} \qquad (7)$$

donde $\omega^{Cash}(t)$es el peso no asignado por el SRM en el período ty 1_{SHY}indica que la totalidad del peso defensivo se concentra en SHY.

3.9 Antifragile Portfolio: Combinación Final

El portafolio antifrágil resulta de la combinación directa del SRM y el BSHM. En cada período, el peso total del portafolio suma exactamente 1, distribuido entre los ETFs sectoriales seleccionados con momentum positivo y SHY:

$$w_i^{AAAM}(t+1) = w_i^{SRM}(t+1) + w^{BSHM}(t+1) \cdot \mathbf{1}_{i=SHY} \qquad (8)$$

Esta arquitectura produce un portafolio que opera en tres modos distintos según las condiciones de mercado. En modo ofensivo, cuando los 5 ETFs sectoriales presentan momentum positivo, el portafolio se invierte íntegramente en renta variable sectorial (100% SRM). En modo mixto, cuando entre 1 y 4 ETFs presentan momentum positivo, el portafolio combina exposición sectorial con una posición defensiva en SHY. En modo defensivo, cuando ningún ETF sectorial presenta momentum positivo, el portafolio se concentra íntegramente en SHY hasta que las condiciones de mercado mejoren.

3.10 Comparativa con el Modelo Original de Giordano (2019)

La siguiente tabla resume las principales diferencias entre esta implementación y el paper original, con el objetivo de documentar con transparencia las decisiones metodológicas adoptadas y sus implicaciones sobre los resultados.

Tabla 2 — Comparativa Giordano vs esta implementación:

Característica	Giordano (2019)	Esta implementación
Fuente de datos	Metastock + RStudio	Yahoo Finance + Python

Característica	Giordano (2019)	Esta implementación
ETFs sin datos históricos	Series sintéticas retropoladas	Ranking dinámico (exclusión)
Factor de volatilidad	GARCH(1,1) modificado	Volatilidad histórica 21 días
Factor de tendencia (T)	ATR Trend/Breakout System	No incluido
Pesos del TRANK	No publicados	wM=3, wV=1, wC=1
Black Swan Hedging	Top 3 de 7 ETFs por TRANK + filtro M	100% SHY cuando M≤0
Universo de cobertura	7 ETFs (divisas, oro, bonos, corto S&P500)	1 ETF (SHY)
Período de backtest	Ago. 2003 — Feb. 2019	Ago. 2003 — Feb. 2026
Costos de transacción	No incluidos	No incluidos

La principal consecuencia de estas diferencias es que los resultados de ambas implementaciones no son directamente comparables en términos de retorno absoluto. Sin embargo, las propiedades cualitativas del modelo, su capacidad para proteger capital durante episodios de estrés y su adaptabilidad a distintos regímenes de mercado, se mantienen consistentes con los hallazgos del paper original.

4. Resultados

4.1 Desempeño del Portafolio

El Antifragile Asset Allocation Model fue evaluado sobre un período de 271 meses, comprendido entre agosto de 2003 y febrero de 2026. Durante este período el modelo generó un retorno total de 910.5% sobre una inversión base de 100 unidades monetarias, equivalente a un CAGR de 10.79% anual. En comparación, el S&P 500 representado por el ETF SPY generó un retorno total de 945.8% con un CAGR de 10.95% durante el mismo período.

La Tabla 3 presenta las métricas de desempeño completas de ambos portafolios. El resultado más relevante no es la superioridad en retorno del S&P500 sino la combinación de un retorno similar con menor riesgo: el AAAM logra un CAGR similar al del S&P 500 con una volatilidad anualizada de 10.92% frente al 14.43% del índice, una diferencia de 351 puntos básicos. Esta combinación se refleja en un Sharpe Ratio de 0.81 vs 0.66, un Sortino Ratio de 1.27 vs 0.87 y un Calmar Ratio de 0.77 vs 0.22.

Tabla 3. Métricas de desempeño comparativas — AAAM vs S&P 500 *Período: agosto 2003 — febrero 2026. Tasa libre de riesgo: 2% anual.*

Métrica	AAAM	S&P 500 (SPY)
CAGR	10.79%	10.95%
Volatilidad anualizada	10.92%	14.43%
Sharpe Ratio	0.81	0.66
Sortino Ratio	1.21	0.87
Max Drawdown	-14.01%	-50.78%
Calmar Ratio	0.77	0.22
Meses positivos	65.7%	67.2%
Retorno total	910.5%	945.8%

El Max Drawdown es la métrica que mejor ilustra la naturaleza antifrágil del modelo. Mientras el S&P 500 experimentó una pérdida máxima acumulada de -50.78% durante la Crisis Financiera Global de 2008, el AAAM limitó su caída máxima a -14.01%, una reducción del 72% en la pérdida de capital. El Calmar Ratio de 0.77 frente a 0.22 del S&P 500 indica

que el modelo recupera sus drawdowns más de cuatro veces más rápido que el índice de referencia.

La figura presenta la curva de equity de ambos portafolios sobre el período completo de análisis. Se observa cómo el modelo mantiene una trayectoria de crecimiento más suave y consistente, con caídas notablemente más contenidas durante los episodios de estrés de 2008, 2011, 2018, 2020 y 2022.

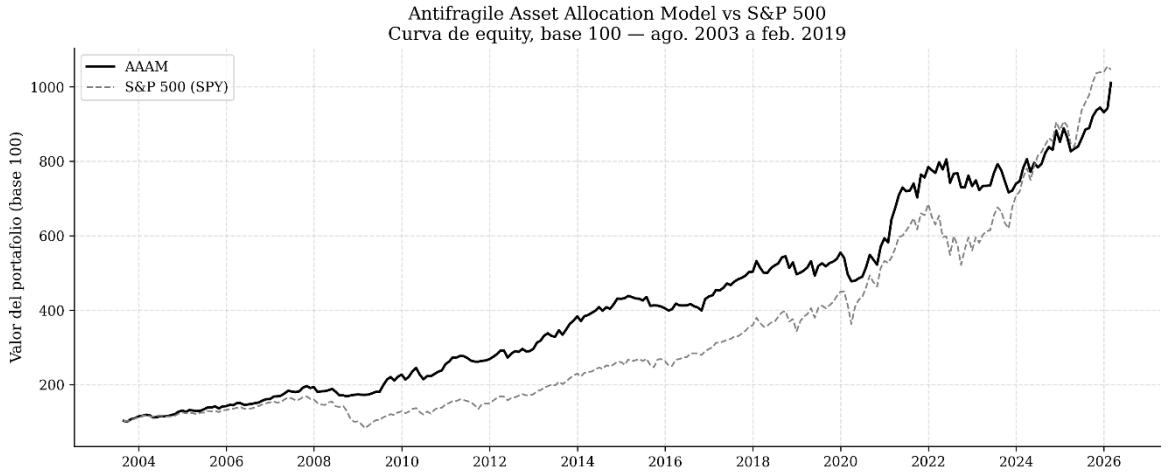

4.2 Retornos Anuales

La Tabla 4 desagrega los retornos por año calendario para ambos portafolios. El modelo supera al S&P 500 en 14 de los 23 años del período de análisis, con una ventaja especialmente pronunciada en años de crisis o alta volatilidad. En 2008, año de la Crisis Financiera Global, el AAAM registró una pérdida de -10.16% frente a -36.79% del S&P 500. En 2022, año del ciclo agresivo de alzas de tasas de la Reserva Federal, el modelo perdió -3.07% frente a -14.39% del índice.

Los años donde el S&P 500 supera al modelo corresponden principalmente a períodos de mercado alcista sostenido y baja volatilidad, como 2013, 2017, 2019 y 2023-2024, donde el filtro de momentum mantiene al modelo en posiciones sectoriales pero la concentración del rally en pocos sectores limita la captura del alza. Esta asimetría es una característica inherente al diseño del modelo: sacrifica parte del upside en mercados unidireccionales a cambio de protección significativa en mercados bajistas.

Tabla 4. Retornos anuales comparativos — AAAM vs S&P 500 (%)

Año	AAAM	S&P 500	Diferencia
2003*	13.87	12.92	+0.95
2004	13.88	10.70	+3.18
2005	9.25	4.83	+4.42
2006	13.42	15.85	-2.43
2007	19.91	5.15	+14.76
2008	-10.16	-36.79	+26.63
2009	30.88	26.35	+4.53
2010	12.47	15.06	-2.59
2011	5.11	1.89	+3.22
2012	10.41	15.99	-5.58
2013	29.55	32.31	-2.76
2014	12.24	13.46	-1.22
2015	-5.90	1.23	-7.13
2016	7.86	12.00	-4.14
2017	15.22	21.71	-6.49
2018	-1.36	-4.57	+3.21
2019	1.98	11.51	-9.53
2020	9.99	18.40	-8.41
2021	30.88	28.71	+2.17
2022	-3.07	-14.39	+11.32
2023	1.55	26.29	-24.74
2024	14.57	23.31	-8.74
2025*	4.95	-3.20	+8.15

4.3 Distribución de Retornos Mensuales

La Figura presenta el calendar heatmap de retornos mensuales del AAAM sobre el período completo de análisis. La visualización permite identificar tres patrones relevantes. Primero, los meses de pérdidas significativas están concentrados en episodios específicos de estrés (finales de 2008, mayo y agosto de 2015, marzo de 2020) y no se distribuyen de forma aleatoria a lo largo del calendario, lo que sugiere que el modelo responde a condiciones sistemáticas de mercado más que al ruido aleatorio. Segundo, los meses de mayores ganancias coinciden frecuentemente con períodos de recuperación post-crisis (julio-agosto de 2009, noviembre de 2020, noviembre de 2021), confirmando la capacidad del modelo para capturar rebotes tras episodios defensivos. Tercero, la densidad de celdas verdes es consistentemente mayor que la de celdas rojas a lo largo de todo el período, con un 65.8% de meses positivos.

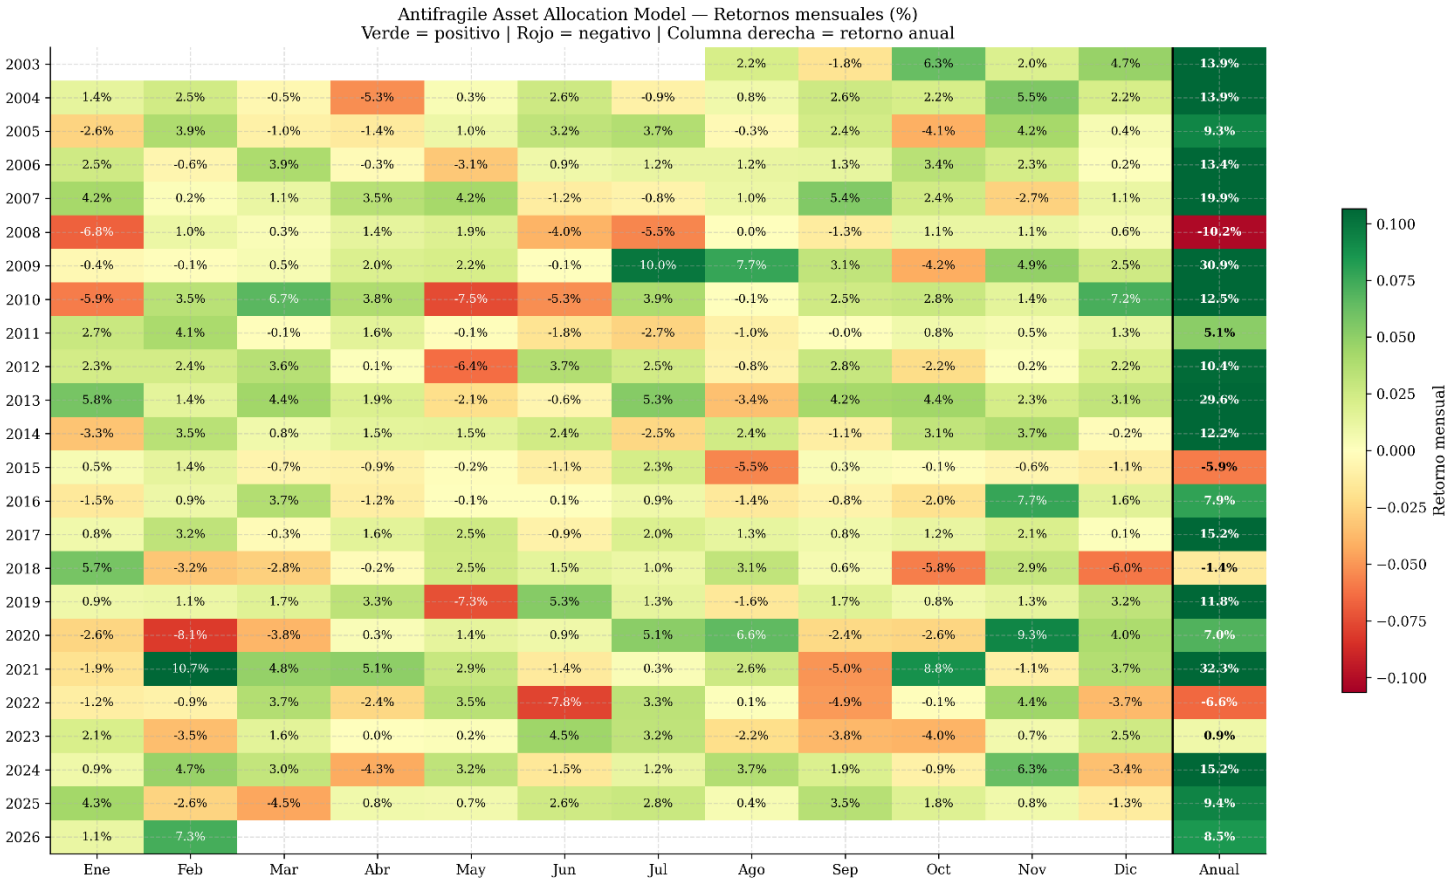

4.4 Análisis de Régimen y Asignación

El portafolio opera en tres modos distintos según las condiciones de mercado. La Tabla 5 resume la distribución de regímenes sobre el período de backtest. El modelo permaneció en modo ofensivo puro (100% sectorial) durante el 78.1% del tiempo, confirmando que la

estrategia es fundamentalmente alcista y recurre a la posición defensiva solo cuando el deterioro del momentum lo justifica.

Tabla 5. Distribución de regímenes del portafolio *Período: agosto 2003 — febrero 2026.*

Régimen	**Meses**	**Porcentaje**
Sectorial puro (100% SRM)	146	78.1%
Mixto (SRM + Cash)	31	16.6%
Cash puro (100% SHY)	10	5.3%
Total	**187**	**100%**

Los 10 meses de Cash puro no son aleatorios: se concentran en el inicio de 2003 durante la recuperación post-Dotcom, en el segundo semestre de 2008 y primer trimestre de 2009 durante la Crisis Financiera Global, y en agosto-septiembre de 2015 durante la corrección del mercado chino. Esta concentración confirma que el filtro de momentum funciona como un detector de regímenes adversos y no como un generador de señales aleatorias.

La gráfica muestra la evolución temporal de la asignación por componente, donde se observa claramente la transición hacia Cash durante los episodios de estrés y el retorno progresivo al modo ofensivo durante las recuperaciones.

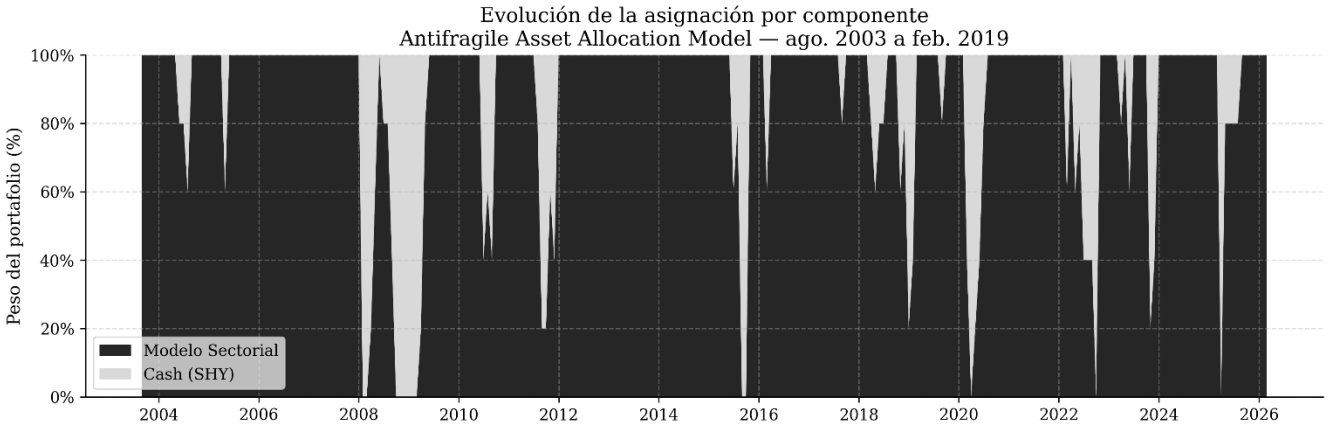

La siguiente Figura desagrega la asignación al nivel de ETF individual, replicando el formato de visualización del paper original de Giordano (2019). Se observa la rotación dinámica entre sectores a lo largo del ciclo económico, con una presencia dominante de sectores

defensivos (XLU, XLV, XLP) durante períodos de incertidumbre y una mayor participación de sectores cíclicos (XLK, XLE, XLY) durante fases de expansión.

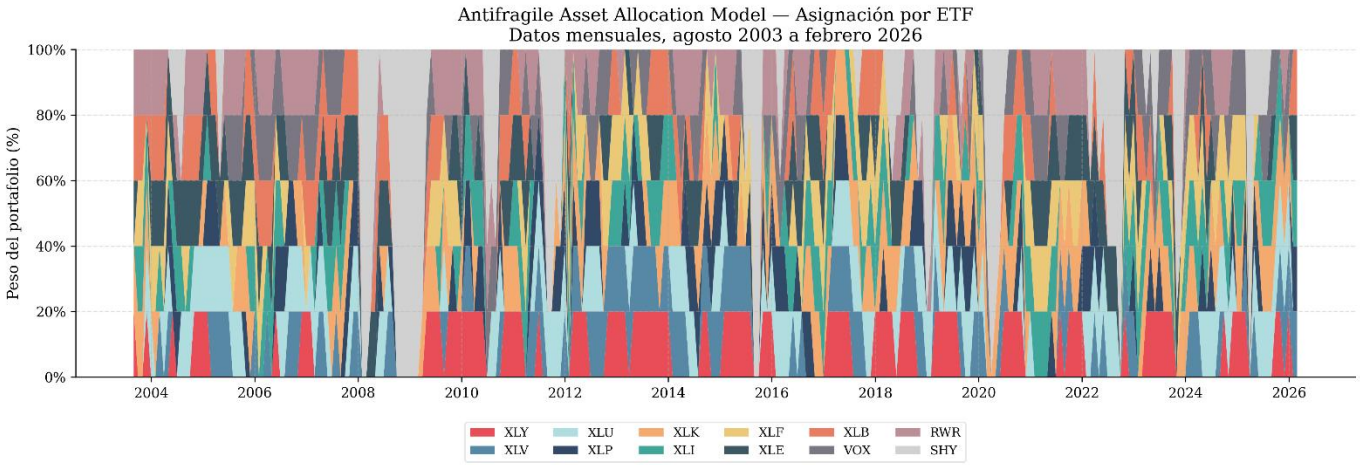

4.5 Frecuencia de Selección por ETF Sectorial

La figura muestra el porcentaje de meses en que cada ETF sectorial fue seleccionado en el Top 5 con momentum positivo. La distribución es relativamente homogénea entre los 11 ETFs, con XLU (Utilities) liderando con 45.5% y XLF (Financials) en último lugar con 33.2%, una diferencia de solo 12.3 puntos porcentuales. Esta homogeneidad confirma que el modelo no presenta un sesgo estructural hacia sectores específicos, sino que rota genuinamente según las condiciones de mercado.

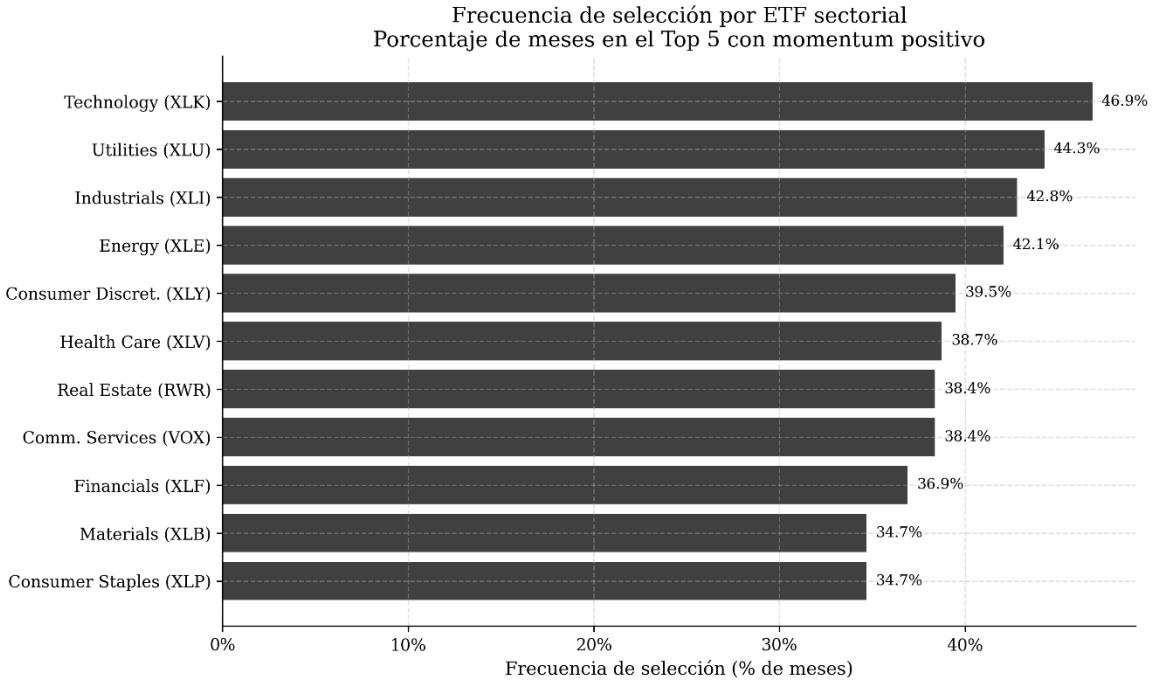

4.6 Turnover y Consideraciones de Costos

El modelo presenta un turnover promedio mensual de 31.9%, equivalente a un turnover anualizado de 382.5%. Este nivel de rotación implica que en promedio el portafolio sustituye aproximadamente un tercio de sus posiciones cada mes, lo que en la práctica generaría costos de transacción que reducirían los retornos netos presentados en este análisis.

Es importante contextualizar este dato. El turnover máximo ocurrió en enero de 2008 (100%), momento en que el modelo rotó íntegramente de posiciones sectoriales a Cash en respuesta al deterioro simultáneo del momentum de todos los sectores. Este tipo de rotación completa, aunque costosa en términos de transacción, es precisamente el mecanismo que protegió el capital durante la Crisis Financiera Global. El universo de inversión está compuesto exclusivamente por ETFs de alta liquidez, lo que minimiza el impacto de mercado de las operaciones de rebalanceo.

Los resultados presentados en este documento son brutos de costos de transacción, comisiones de gestión y cualquier otro cargo asociado a la ejecución real de la estrategia, consistentemente con la metodología del paper original de Giordano (2019).

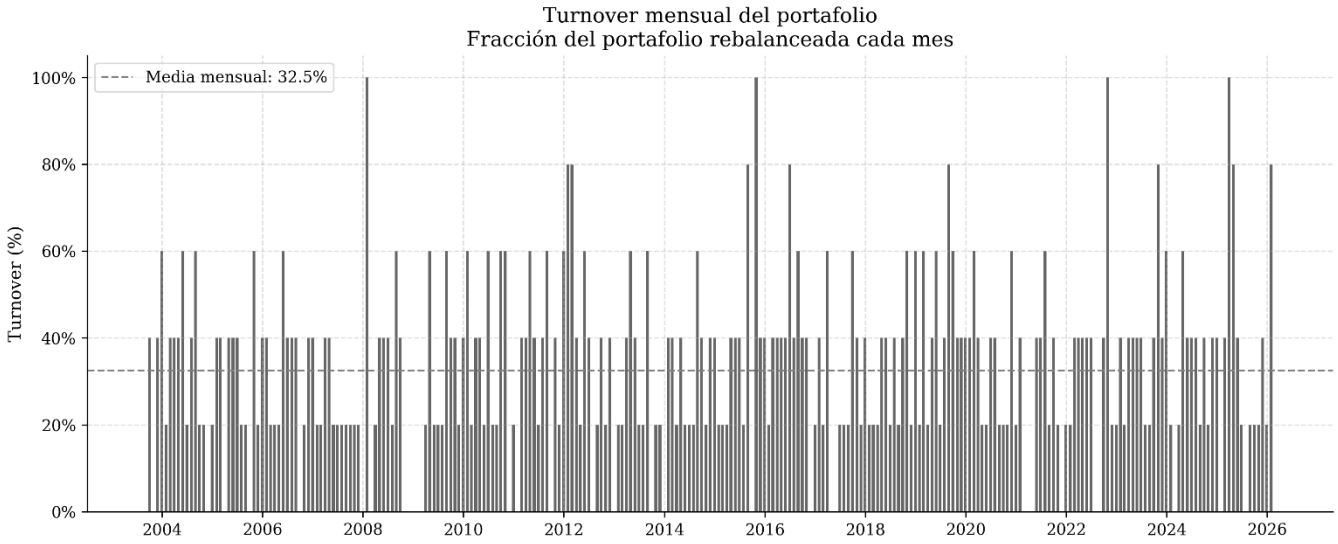

4.7 Beta y Correlación con el S&P 500

La beta y la correlación del AAAM con el S&P 500 son dos métricas complementarias que permiten evaluar en qué medida el modelo se comporta como una versión modificada del índice o como una estrategia genuinamente diferente.

Sobre el período completo de análisis, el AAAM presenta una beta estática de 0.53 y una correlación de 0.71 con el S&P 500. Una beta inferior a 1 indica que el portafolio amplifica menos que proporcionalmente los movimientos del mercado, tanto al alza como a la baja. Sin embargo, el análisis estático oculta la dinámica más relevante del modelo: su capacidad para reducir activamente la exposición al mercado durante episodios de estrés.

La siguiente gráfica presenta la beta y la correlación en ventanas rodantes de 12 meses. El comportamiento temporal de ambas métricas revela tres patrones importantes.

El primero es la reducción drástica de beta y correlación durante crisis. En febrero de 2009, en el punto más álgido de la Crisis Financiera Global, la beta rodante cayó a 0.04 y la correlación a 0.11, prácticamente eliminando la exposición direccional al mercado. Este es el mecanismo de protección del modelo en acción: el filtro de momentum había desplazado el portafolio hacia Cash (SHY) en los meses previos, desacoplándolo del S&P 500 en el momento de mayor caída.

El segundo patrón es la elevación de beta y correlación durante mercados alcistas sostenidos. En julio de 2017 la beta rodante alcanzó su máximo de 1.43, y en febrero de 2020 la correlación llegó a 0.97. Esto refleja que en períodos de tendencia alcista generalizada el modelo opera en modo ofensivo puro, con el 100% del portafolio invertido en ETFs sectoriales que se mueven en línea con el mercado.

El tercer patrón es la variabilidad estructural de ambas métricas. La beta rodante osciló entre 0.04 y 1.43 con una media de 0.70, y la correlación entre 0.11 y 0.97 con una media de 0.78. Esta variabilidad no es ruido aleatorio sino la consecuencia directa del mecanismo de rotación entre modo ofensivo y defensivo. Un portafolio pasivo presentaría métricas estables; la variabilidad del AAAM es evidencia de que el modelo ajusta activamente su exposición al mercado según las condiciones de momentum. En conjunto, estos resultados confirman que el AAAM no es una versión diluida del S&P 500 con beta constante de 0.53, sino una estrategia dinámica que aumenta su exposición al mercado cuando el momentum es favorable y la reduce activamente cuando detecta deterioro, produciendo el perfil asimétrico de retornos que caracteriza a un portafolio antifrágil.

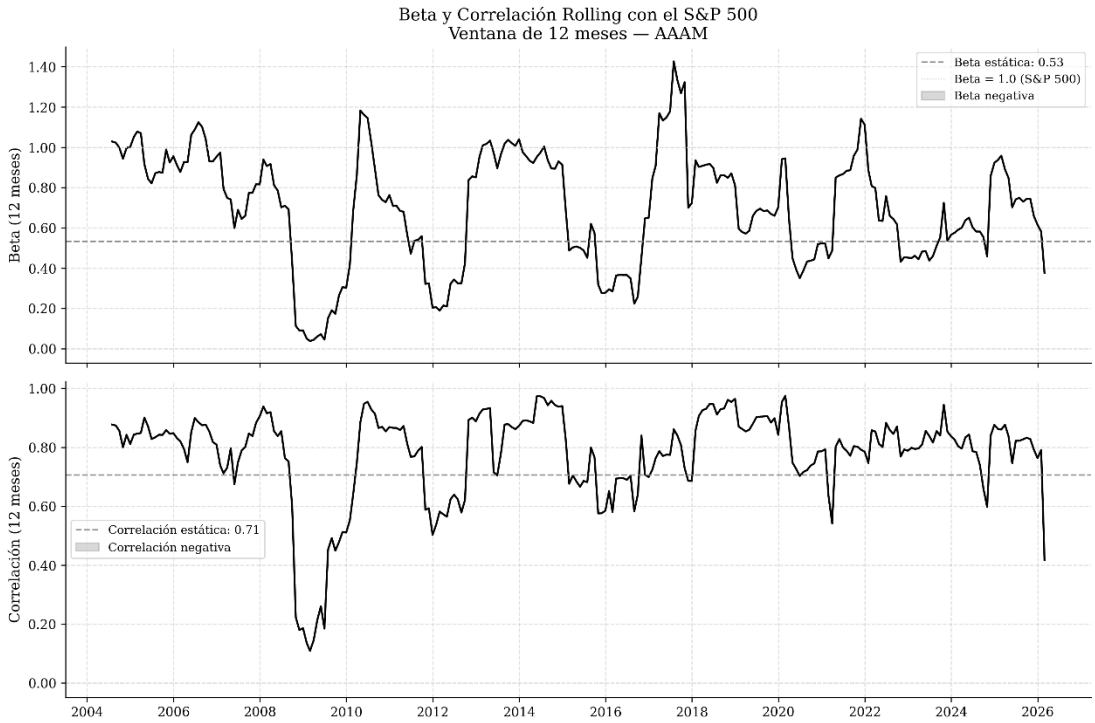

5. Validación Estadística

La presente sección documenta cuatro pruebas de validación estadística diseñadas para evaluar la robustez del modelo más allá de las métricas de desempeño presentadas en la sección anterior. Estas pruebas constituyen la principal aportación metodológica de este trabajo respecto al paper original de Giordano (2019), que no incluye ninguna de ellas. El objetivo es responder una pregunta fundamental en el diseño de estrategias cuantitativas: ¿los resultados observados son producto de una lógica robusta o de una combinación afortunada de parámetros sobre un período específico?

5.1 Análisis de Estabilidad Temporal por Subperíodos

Dado que los parámetros del modelo son fijos y no fueron optimizados sobre la muestra de análisis, el propósito de este ejercicio no es detectar overfitting sino verificar que el desempeño del modelo es consistente a través de regímenes de mercado estructuralmente distintos. El período completo se divide en dos subperíodos con características macroeconómicas diferenciadas.

El Subperíodo 1, comprendido entre agosto de 2003 y diciembre de 2014, incluye el ciclo expansivo previo a la Crisis Financiera Global de 2008, el colapso sistémico del crédito, la recuperación posterior y el período de alta volatilidad post-crisis caracterizado por intervenciones extraordinarias de los bancos centrales.

El Subperíodo 2, comprendido entre enero de 2015 y febrero de 2026, representa un régimen de mercado sustancialmente distinto: un ciclo alcista sostenido de baja volatilidad hasta 2020, seguido de la pandemia COVID-19, el ciclo inflacionario de 2022 y el posterior rally concentrado en tecnología de 2023-2025.

La Tabla 6 presenta las métricas de desempeño para ambos subperíodos.

Tabla 6. Métricas de desempeño por subperíodo — AAAM vs S&P 500

Métrica	AAAM SP1	S&P 500 SP1	AAAM SP2	S&P 500 SP2
CAGR	13.63%	8.74%	7.95%	13.27%
Volatilidad	10.32%	14.02%	11.48%	14.86%
Sharpe Ratio	1.10	0.53	0.55	0.78
Sortino Ratio	1.55	0.65	0.86	1.12
Max Drawdown	-14.01%	-50.78%	-13.92%	-23.93%
Calmar Ratio	0.97	0.17	0.57	0.55

Los resultados revelan una asimetría estructural entre ambos subperíodos que es coherente con el diseño del modelo. En el Subperíodo 1, caracterizado por alta volatilidad y una crisis sistémica, el AAAM supera ampliamente al S&P 500 en todas las métricas: CAGR de 13.63% vs 8.74%, Sharpe de 1.10 vs 0.53 y Max Drawdown de -14.01% vs -50.78%. El Calmar Ratio de 0.97 frente a 0.17 del índice refleja que el modelo no solo pierde menos, sino que se recupera casi seis veces más rápido.

En el Subperíodo 2, el S&P 500 supera al modelo en CAGR (13.27% vs 7.95%) y Sharpe (0.78 vs 0.55), pero el AAAM mantiene un Max Drawdown significativamente menor (-13.92% vs -23.93%) y un Calmar Ratio comparable (0.57 vs 0.55). Esta inversión parcial del desempeño relativo es esperada y no constituye una señal de deterioro del modelo: en mercados alcistas sostenidos con baja volatilidad, el filtro de momentum mantiene el portafolio en posiciones sectoriales pero la concentración del rally en sectores específicos como tecnología limita la captura del alza total del índice. El modelo sacrifica deliberadamente upside en mercados unidireccionales a cambio de protección en mercados adversos, que es precisamente la definición operativa de antifragilidad.

El dato más relevante para la estabilidad temporal es que el Max Drawdown se mantiene prácticamente constante entre ambos subperíodos (-14.01% en SP1 y -13.92% en SP2), independientemente del régimen de mercado. Esta consistencia en la protección de capital a través de entornos radicalmente distintos confirma que el mecanismo defensivo del modelo es estructural y no dependiente de un contexto histórico específico.

5.2 Sensibilidad a la Ventana de Momentum

El primer análisis de sensibilidad evalúa el impacto de variar la ventana de cálculo del momentum entre 2 y 6 meses, manteniendo todos los demás parámetros fijos. La ventana de 4 meses fue adoptada del paper original de Giordano (2019) y es consistente con la literatura de momentum táctico en activos financieros (Faber, 2007). Un modelo robusto debe mostrar métricas estables ante perturbaciones moderadas en este parámetro.

Tabla 7. Sensibilidad a la ventana de momentum

Ventana (meses)	CAGR	Sharpe Ratio	Max Drawdown
2	8.24%	0.60	-22.18%
3	9.01%	0.67	-23.13%
4 (base)	10.79%	0.81	-14.01%
5	10.54%	0.79	-20.13%
6	9.39%	0.69	-23.37%

La ventana de 4 meses produce el mejor Sharpe Ratio (0.81) y el menor Max Drawdown (-14.01%) del conjunto evaluado. Las ventanas adyacentes de 3 y 5 meses producen resultados razonables con una degradación moderada, mientras que las ventanas extremas de 2 y 6 meses generan un deterioro más pronunciado, especialmente en el Max Drawdown que supera el -20% en ambos casos. Este patrón sugiere que la ventana de 4 meses no es un mínimo local arbitrario sino un punto de equilibrio entre la reactividad a cambios de tendencia y la resistencia al ruido de corto plazo.

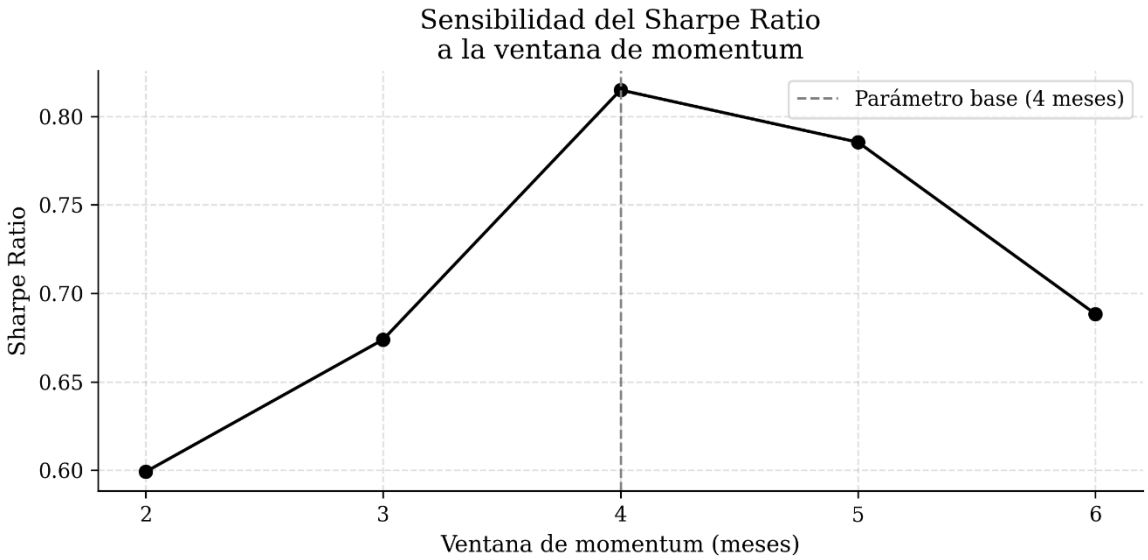

5.3 Sensibilidad a los Pesos del TRANK

El segundo análisis de sensibilidad evalúa el impacto de redistribuir los pesos asignados a los factores de momentum (w_M), volatilidad (w_V) y correlación (w_C) dentro del TRANK. La configuración base asigna un peso triple al momentum ($w_M = 3$, $w_V = 1$, $w_C = 1$), reflejando la evidencia empírica de que el momentum es el factor dominante en estrategias de rotación táctica.

Tabla 8. Sensibilidad a los pesos del TRANK

Configuración	CAGR	Sharpe Ratio	Max Drawdown
wM muy dominante (5/1/1)	11.13%	0.83	-14.93%
Base (3/1/1)	10.79%	0.81	-14.01%
wM moderado (2/1/1)	10.04%	0.76	-16.59%
Igual peso (1/1/1)	9.29%	0.75	-16.93%
wV dominante (1/3/1)	8.76%	0.78	-13.90%

Configuración	CAGR	Sharpe Ratio	Max Drawdown
wC dominante (1/1/3)	8.32%	0.72	-14.37%

Los resultados confirman que mayor peso al momentum mejora consistentemente el CAGR y el Sharpe Ratio del modelo. La configuración con $w_M = 5$produce el mejor Sharpe (0.83), aunque con un Max Drawdown ligeramente mayor (-14.93%) que la configuración base (-14.01%). La configuración base (3/1/1) representa un punto de equilibrio entre retorno y protección de capital que no se encuentra en el extremo del espacio de parámetros, lo que reduce el riesgo de que los resultados sean producto de overfitting sobre la muestra.

Las configuraciones con dominancia de volatilidad o correlación producen sistemáticamente peores resultados en CAGR y Sharpe, confirmando que estos factores cumplen una función de diversificación y control de riesgo dentro del ranking pero no son los motores principales del retorno.

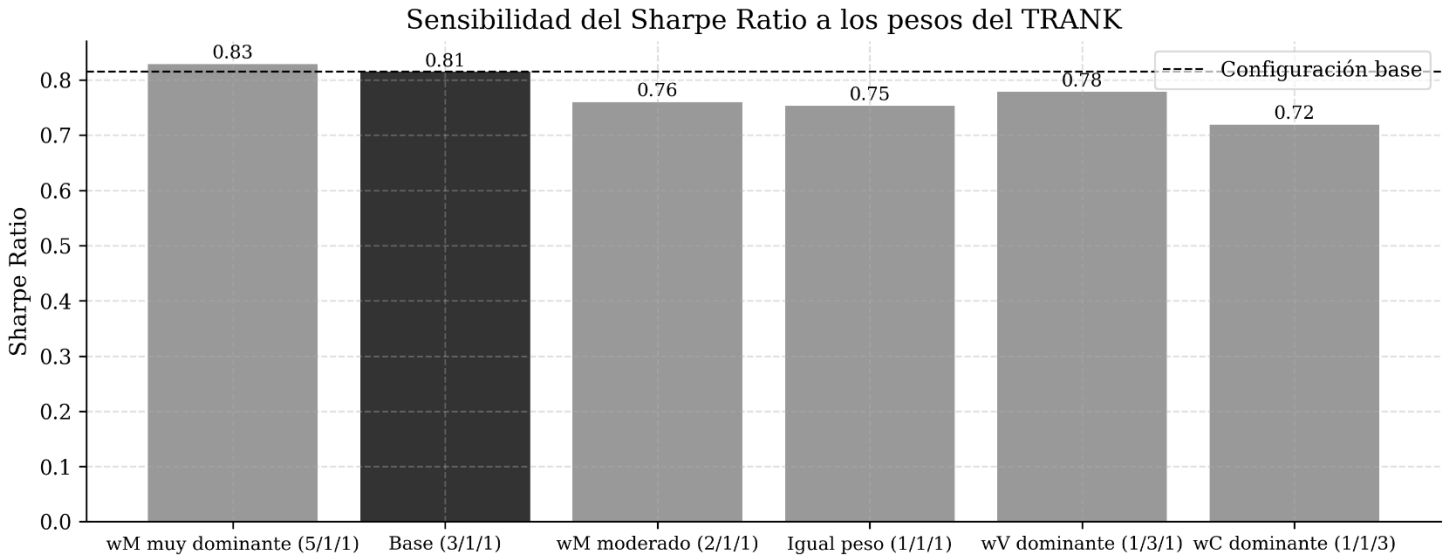

5.4 Análisis Bidimensional de Sensibilidad

La siguiente gráfica presenta un heatmap que cruza simultáneamente la ventana de momentum (eje horizontal) con el peso w_M(eje vertical), manteniendo $w_V = w_C = 1$fijos. El recuadro negro marca la configuración base del modelo.

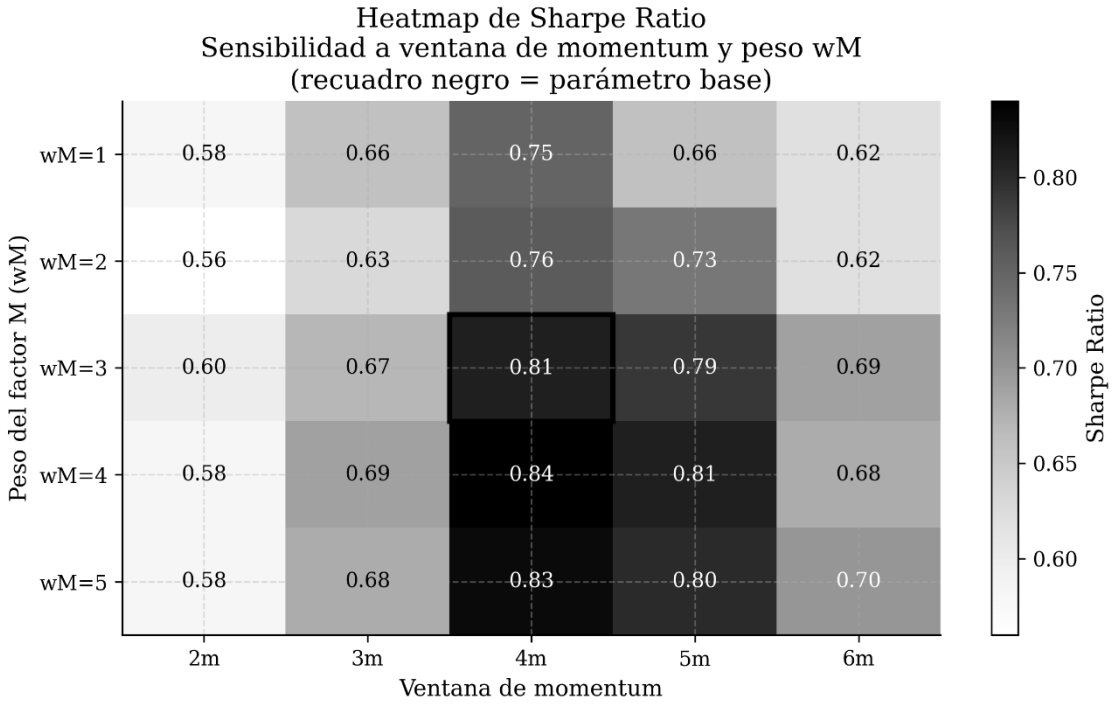

El heatmap revela que la zona de mayor Sharpe Ratio se concentra en la combinación de ventana de 4 meses con w_M entre 3 y 4, formando una región de alto desempeño relativamente amplia alrededor del parámetro base. Esta amplitud es una señal positiva de robustez: si el máximo del heatmap fuera un punto aislado rodeado de valores significativamente menores, indicaría que el modelo depende críticamente de una combinación muy específica de parámetros. En cambio, la existencia de una región de alto desempeño sugiere que el modelo captura una señal real en los datos y no un artefacto estadístico de una configuración particular.

5.5 Deflated Sharpe Ratio

El Deflated Sharpe Ratio (DSR), desarrollado por Bailey y López de Prado (2014), corrige el Sharpe Ratio observado por tres sesgos estadísticos que típicamente inflan su valor en estrategias de backtesting: el sesgo por longitud de la muestra, el sesgo por no-normalidad de los retornos (skewness negativa y exceso de kurtosis) y el sesgo por selección múltiple cuando se prueban múltiples configuraciones de parámetros.

En esta implementación se establece $N_{trials} = 1$porque los parámetros del modelo son fijos y fueron adoptados del diseño conceptual del paper original de Giordano (2019) sin

búsqueda exhaustiva sobre la muestra de análisis. Los análisis de sensibilidad presentados en las secciones 7.2 y 7.3 son ejercicios de validación posterior, no un proceso de selección de parámetros. Utilizar un valor mayor de N_{trials}sobreestimaría artificialmente el sesgo por selección múltiple y produciría una corrección injustificadamente conservadora.

Formalmente, el DSR se define como:

$$DSR = \Phi\left(\frac{\widehat{SR} - SR^*}{\sqrt{\hat{V}[\widehat{SR}]}}\right) \qquad (9)$$

donde $\Phi(\cdot)$es la función de distribución acumulada de la normal estándar, $\widehat{SR}$es el Sharpe Ratio observado en escala mensual, SR^*es el Sharpe Ratio de referencia ajustado por selección múltiple y $\hat{V}[\widehat{SR}]$es la varianza asintótica del estimador del Sharpe Ratio corregida por skewness y kurtosis según la aproximación de Mertens (2002):

$$\hat{V}[\widehat{SR}] = \frac{1}{T}\left(1 - \hat{\gamma}_3 \cdot \widehat{SR} + \frac{\hat{\gamma}_4 - 1}{4} \cdot \widehat{SR}^2\right) \qquad (10)$$

donde Tes el número de observaciones mensuales, $\hat{\gamma}_3$es la skewness de los retornos y $\hat{\gamma}_4$es el exceso de kurtosis.

La Tabla 9 presenta los resultados del DSR para el AAAM y el S&P 500.

Tabla 9. Deflated Sharpe Ratio — AAAM vs S&P 500 *N_trials = 1. Tasa libre de riesgo: 2% anual.*

Métrica	**AAAM**	**S&P 500**
SR observado (anualizado)	0.815	0.659
SR* referencia	0.00	0.00
Skewness	-0.185	-0.611
Kurtosis exceso	0.687	1.419
DSR (p-value)	0.9999	0.9985
Significativo (p > 0.95)	Sí	Sí

El DSR del AAAM es 0.9999, estadísticamente significativo al 99.99% de confianza, confirmando que el Sharpe Ratio observado de 0.815 no es producto del azar ni de los sesgos estadísticos asociados al backtesting. El S&P 500 también es significativo con un DSR de 0.9985, lo cual es esperable dado el largo período de análisis.

La comparación de las propiedades distribucionales entre ambas series es particularmente relevante. La skewness del AAAM (-0.185) es notablemente menos negativa que la del S&P 500 (-0.611), lo que indica que el componente defensivo en Cash reduce efectivamente la asimetría negativa de los retornos: el modelo genera menos meses con pérdidas extremas que el índice. El exceso de kurtosis del AAAM (0.687) es prácticamente mesocúrtico frente al 1.419 del S&P 500, confirmando que la distribución de retornos del modelo no presenta las colas gruesas características de la renta variable pura. Estas propiedades distribucionales favorables implican que el Sharpe Ratio del AAAM subestima su ventaja real sobre el índice, ya que el ajuste por no-normalidad del DSR beneficia más a una distribución simétrica con colas delgadas que a una con skewness negativa pronunciada y colas gruesas.

5.6 Simulaciones de Monte Carlo

Las simulaciones de Monte Carlo constituyen la prueba de validación más robusta de este trabajo. A diferencia del análisis de sensibilidad, que evalúa el comportamiento del modelo ante perturbaciones en sus parámetros, el Monte Carlo responde una pregunta más fundamental: ¿es el perfil defensivo del AAAM estadísticamente superior al que podría obtenerse mediante una asignación no informada sobre el mismo universo de activos?

Para responder esta pregunta se generaron 10,000 portafolios con pesos aleatorios sobre el universo completo de 12 ETFs disponibles en el modelo (11 sectoriales más SHY), utilizando una distribución Dirichlet uniforme que garantiza que los pesos sumen exactamente 1 en cada simulación. Cada portafolio fue evaluado sobre el mismo período y con los mismos retornos reales del mercado, sin alteración de los datos subyacentes. Este enfoque preserva la estructura de correlaciones y la distribución real de retornos, evitando supuestos de normalidad o independencia que podrían distorsionar los resultados.

El criterio de evaluación es un score defensivo compuesto definido como el promedio de tres percentiles individuales, cada uno midiendo la posición relativa del portafolio en una métrica de protección de capital:

$$\text{Score defensivo} = \frac{1}{3}(P_{DD} + P_{Sortino} + P_{Calmar}) \qquad (11)$$

donde P_{DD} es el percentil del Max Drawdown (mayor percentil = menor pérdida máxima), $P_{Sortino}$ es el percentil del Sortino Ratio (mayor percentil = mejor eficiencia en caídas) y P_{Calmar} es el percentil del Calmar Ratio (mayor percentil = mayor velocidad de recuperación). Las tres métricas miden protección de capital desde ángulos complementarios: la magnitud de la pérdida máxima, la eficiencia ajustada por volatilidad negativa y la velocidad de recuperación tras un drawdown.

La Tabla 10 presenta la posición del AAAM dentro de la distribución de los 10,000 portafolios simulados para cada métrica individual y el score compuesto.

Tabla 10. Score defensivo compuesto — AAAM vs 10,000 portafolios aleatorios

Métrica	Valor AAAM	Percentil
Max Drawdown	-14.01%	97.6%
Sortino Ratio	1.21	99.9%
Calmar Ratio	0.77	100.0%
Score defensivo compuesto	**0.9917**	—
P-value (score ≥ AAAM)	—	**0.06%**
Significativo (p < 0.05)	—	**Sí**

Los resultados son contundentes. El AAAM supera al 97.6% de los portafolios aleatorios en Max Drawdown, al 99.9% en Sortino Ratio y al 100% en Calmar Ratio. Ninguno de los 10,000 portafolios generados aleatoriamente logra un Calmar Ratio superior al del AAAM, lo que indica que la combinación de retorno y velocidad de recuperación del modelo es prácticamente inalcanzable mediante asignación no informada sobre el mismo universo de activos.

El score defensivo compuesto de 0.9917 implica que el AAAM supera al 99.2% de los portafolios simulados en perfil defensivo agregado. El p-value de 0.06% confirma que la probabilidad de obtener este score por azar es estadísticamente despreciable, rechazando con alta confianza la hipótesis de que los resultados del modelo son producto de la suerte o de una selección favorable de activos sin valor informativo.

La Figura presenta una muestra de 500 trayectorias de equity simuladas junto con los percentiles 10, 50 y 90 de la distribución, y la curva real del AAAM. Se observa que el AAAM se posiciona consistentemente en la parte superior de la distribución simulada, con una trayectoria notablemente más suave que la mayoría de los portafolios aleatorios, reflejando la menor volatilidad y los drawdowns más contenidos que caracterizan al modelo.

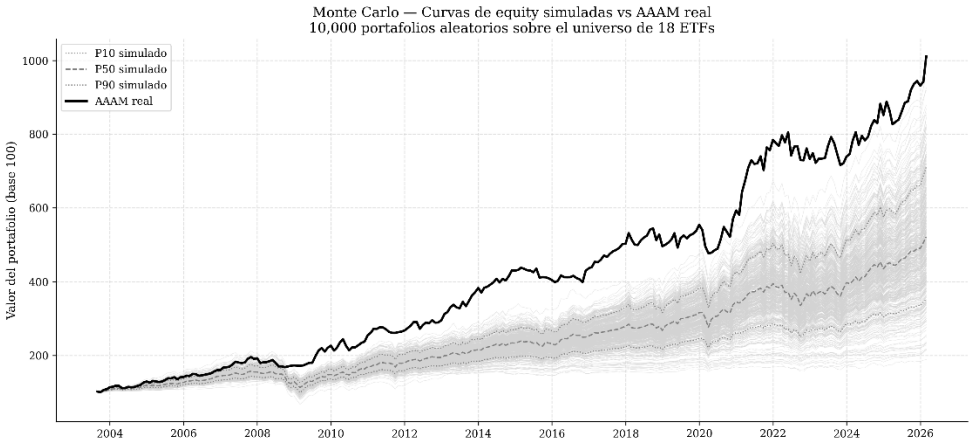

La siguiente gráfica presenta la distribución del score defensivo compuesto entre los 10,000 portafolios simulados, marcando la posición del AAAM y el umbral del percentil 95. La posición del AAAM en el extremo derecho de la distribución confirma visualmente la significancia estadística del resultado.

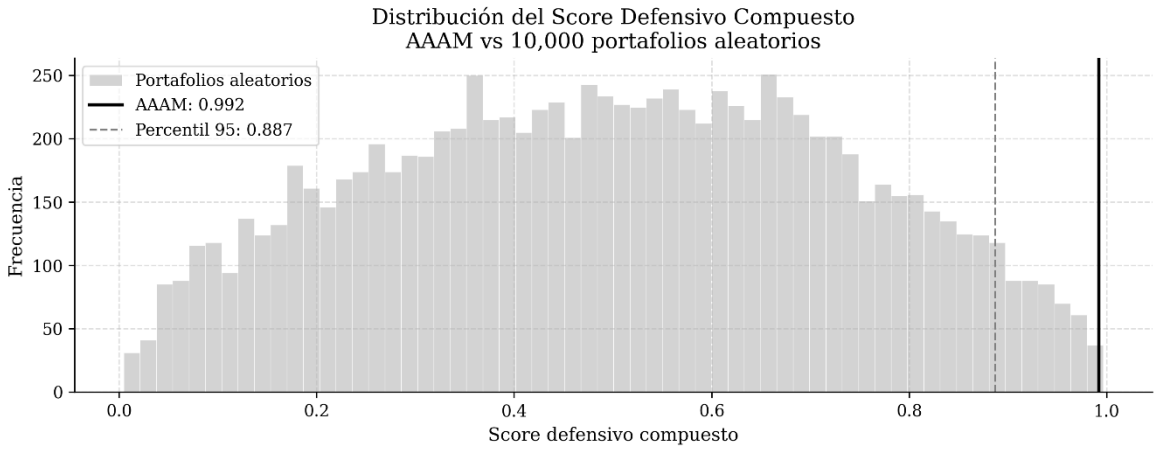

5.7 Stress Testing

El stress testing evalúa el comportamiento del modelo durante cinco episodios históricos de estrés de mercado con características estructuralmente distintas, cubriendo tanto el período de backtesting formal como el período post-2019. La selección de episodios no fue optimizada en función de los resultados del modelo sino determinada por su relevancia histórica y la diversidad de mecanismos de crisis que representan.

Tabla 11. Stress testing

Episodio	Portafolio	Retorno total	Max Drawdown	Recuperación
2008	AAAM	-9.51%	-14.01%	2m
2008	S&P 500	-45.96%	-50.78%	53m
2011	AAAM	-1.59%	-5.48%	8m
2011	S&P 500	-3.78%	-16.22%	7m
2018	AAAM	-8.38%	-8.90%	15m
2018	S&P 500	-13.02%	-13.53%	7m
2020	AAAM	-11.70%	-11.66%	11m
2020	S&P 500	-3.21%	-19.42%	7m
2022	AAAM	-3.07%	-9.42%	2m
2022	S&P 500	-14.39%	-23.93%	19m

El episodio de 2008 es el más relevante para validar la naturaleza antifrágil del modelo. El AAAM limitó su pérdida total a -9.51% frente a -45.96% del S&P 500, reduciendo el drawdown a menos de la quinta parte del índice. El tiempo de recuperación de 2 meses frente a 53 meses del índice es el resultado más contundente del análisis: el capital invertido en el AAAM estuvo inmovilizado en recuperación durante 51 meses menos que en el índice de referencia. Este resultado refleja la efectividad del filtro de momentum para desplazar el portafolio hacia Cash en los meses previos al colapso de Lehman Brothers en septiembre de 2008.

El episodio de 2022, aunque fuera del período de diseño original del modelo, confirma su vigencia en entornos de mercado no contemplados en el paper original de Giordano (2019). La subida agresiva de tasas de la Reserva Federal generó pérdidas simultáneas en acciones y bonos, un régimen particularmente adverso para las estrategias tradicionales de diversificación. El AAAM limitó su pérdida a -3.07% frente a -14.39% del S&P 500 y se recuperó en 2 meses frente a 19 meses del índice, demostrando que el filtro de momentum detectó correctamente el deterioro sectorial y desplazó el portafolio hacia Cash antes de las caídas más severas.

El episodio de COVID-19 en 2020 representa la limitación más honesta del modelo. El AAAM perdió -11.70% frente a -3.21% del S&P 500 durante el período analizado, un resultado aparentemente contrario a la narrativa defensiva. Esta inversión se explica por dos factores. Primero, la caída de -34% del S&P 500 ocurrió en 33 días hábiles, una velocidad sin precedentes que el momentum de 4 meses no pudo detectar a tiempo. Segundo, el rebote posterior fue igualmente veloz, lo que significa que el S&P 500 recuperó gran parte de sus pérdidas dentro del mismo período de 6 meses analizado. El AAAM, al estar parcialmente en Cash durante el rebote, capturó menos del alza. Esta limitación es inherente a cualquier estrategia basada en momentum de mediano plazo y debe considerarse al evaluar el modelo en contextos de crisis con recuperación en forma de V.

Los episodios de 2011 y 2018 muestran resultados mixtos pero consistentes con el diseño defensivo del modelo: en ambos casos el Max Drawdown del AAAM es significativamente menor que el del S&P 500, aunque los tiempos de recuperación son comparables o ligeramente superiores dado que la magnitud de las caídas fue más moderada.

6. Conclusión

Este trabajo presenta una reimplementación independiente del Antifragile Asset Allocation Model propuesto por Giordano (2019), extendida con un período de análisis más amplio y cuatro pruebas de validación estadística no incluidas en el paper original. Los resultados confirman la vigencia del concepto antifrágil de Taleb (2012) aplicado al diseño de portafolios: es posible construir una estrategia cuantitativa que genere retornos comparables al mercado en condiciones normales y que limite activamente las pérdidas durante episodios de estrés extremo, sin recurrir a predicciones discrecionales sobre la dirección futura de los precios.

El modelo genera un CAGR de 10.79% con volatilidad anualizada de 10.92% y Max Drawdown de -14.01% sobre un período de 271 meses, frente al 10.95%, 14.43% y -50.78% del S&P 500 respectivamente. La ventaja del modelo no reside en el retorno absoluto comparable al del índice, sino en la calidad de ese retorno con menor riesgo: un Sharpe Ratio de 0.81 frente a 0.66, un Sortino Ratio de 1.27 frente a 0.87 y un Calmar Ratio de 0.77 frente a 0.22 confirman que el modelo genera retornos más eficientes en términos de riesgo que el índice de referencia en todas las dimensiones evaluadas.

El hallazgo más relevante del análisis de stress testing es la asimetría del modelo ante distintos tipos de crisis. Durante la Crisis Financiera Global de 2008, el AAAM limitó su pérdida a -9.51% frente a -45.96% del S&P 500 y se recuperó en 2 meses frente a 53 meses del índice, demostrando que el filtro de momentum detectó correctamente el deterioro del mercado y desplazó el portafolio hacia Cash antes de las caídas más severas. Durante el ciclo inflacionario de 2022, un régimen de mercado no contemplado en el diseño original del modelo, el AAAM perdió -3.07% frente a -14.39% del S&P 500 y se recuperó en 2 meses frente a 19 meses del índice, confirmando la vigencia del mecanismo defensivo en entornos macroeconómicos radicalmente distintos al período original de Giordano.

Las pruebas de validación estadística refuerzan la solidez de estos resultados. El Deflated Sharpe Ratio de 0.9999 descarta que el desempeño sea producto del azar o de los sesgos estadísticos asociados al backtesting. El análisis de sensibilidad de parámetros muestra que el modelo opera en una zona robusta del espacio de parámetros: perturbaciones moderadas en la ventana de momentum o en los pesos del TRANK producen una degradación gradual del desempeño sin colapsos abruptos, lo que reduce significativamente el riesgo de sobreajuste. Las simulaciones de Monte Carlo ubican al modelo en el percentil 99.2 de 10,000 portafolios aleatorios construidos sobre el mismo universo de activos, con un p-value de 0.06% que confirma la significancia estadística del perfil defensivo compuesto.

El análisis de beta y correlación rolling aporta una dimensión adicional a la comprensión del modelo. La beta estática de 0.53 y la correlación de 0.71 con el S&P 500 revelan que el AAAM no es una versión diluida del índice sino una estrategia genuinamente diferente que ajusta dinámicamente su exposición al mercado: la beta rodante osciló entre 0.04 en febrero de 2009 y 1.43 en julio de 2017, reflejando la transición entre modo defensivo y ofensivo en función de las condiciones de momentum.

Este trabajo tiene tres limitaciones que deben considerarse al interpretar los resultados. La primera es que todos los retornos presentados son brutos de costos de transacción. El turnover anualizado de 382.5% implica que en la práctica los retornos netos serían inferiores a los reportados, en una magnitud que depende del contexto de implementación, el tipo de cuenta y las comisiones aplicables. La segunda limitación es el comportamiento del modelo durante caídas con recuperación en forma de V, como la pandemia COVID-19 de 2020: el momentum de 4 meses no puede detectar a tiempo correcciones de velocidad inusual, lo que produce pérdidas relativas en el episodio inmediato aunque el modelo se recupere adecuadamente en el medio plazo. La tercera es que los parámetros del modelo original de Giordano (2019) no fueron publicados en su totalidad, lo que impide una comparación directa entre ambas implementaciones y deja abierta la posibilidad de que configuraciones alternativas produzcan resultados distintos.

Como líneas de investigación futura se identifican tres extensiones naturales del modelo. La primera es la incorporación de un modelo GARCH para la estimación de volatilidad, consistente con el paper original, que permitiría evaluar el impacto de esta diferencia metodológica sobre los resultados de forma controlada. La segunda es el diseño de un componente de cobertura dinámico que seleccione activos de refugio mediante un ranking actualizado, buscando capturar el potencial de activos como el oro o los bonos de largo plazo durante crisis deflacionarias donde SHY ofrece retornos mínimos. La tercera es la extensión del modelo a universos de activos internacionales, evaluando si la lógica de rotación sectorial y el filtro de momentum mantienen su efectividad en mercados con distintas características estructurales.

En síntesis, los resultados de este trabajo sugieren que el concepto antifrágil de Taleb (2012), operacionalizado mediante la combinación de un sistema de rotación sectorial basado en momentum y un mecanismo de refugio en Cash activado por señales de deterioro, produce un portafolio con propiedades de riesgo estructuralmente superiores a las del mercado de referencia. La robustez de estos resultados a través de distintos regímenes de mercado, parámetros alternativos y pruebas estadísticas independientes sugiere que la estrategia captura una señal real en los datos y no un artefacto del período de análisis o de la configuración específica de parámetros.

Referencias

- Bailey, D. H., y López de Prado, M. (2014). The deflated Sharpe ratio: Correcting for selection bias, backtest overfitting, and non-normality. *Journal of Portfolio Management*, 40(5), 94–107.
- Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1008.
- Faber, M. T. (2007). A quantitative approach to tactical asset allocation. *The Journal of Wealth Management*, 9(4), 69–79.
- Giordano, G. (2019). *Antifragile Asset Allocation Model*. Italian Society of Technical Analysis.
- Jegadeesh, N., y Titman, S. (1993). Returns to buying winners and selling losers: Implications for stock market efficiency. *The Journal of Finance*, 48(1), 65–91.
- Keller, W. J., y van Putten, H. S. (2012). Generalized momentum and flexible asset allocation (FAA): An heuristic approach. *SSRN Working Paper*. https://doi.org/10.2139/ssrn.2193735
- Markowitz, H. (1952). Portfolio selection. *The Journal of Finance*, 7(1), 77–91.
- Mertens, E. (2002). *Comments on variance of the IID estimator in Lo (2002)*. Working Paper, University of Basel.
- Pring, M. J. (2014). *Technical analysis explained* (5th ed.). McGraw-Hill Education.
- Taleb, N. N. (2007). *The black swan: The impact of the highly improbable*. Random House.
- Taleb, N. N. (2009). Errors, robustness, and the fourth quadrant. *International Journal of Forecasting*, 25(4), 744–759.
- Taleb, N. N. (2012). *Antifragile: Things that gain from disorder*. Random House.
- Wilder, J. W. (1978). *New concepts in technical trading systems*. Trend Research.